

An Empirical Study of Data Scale, Model Complexity, and Input Modalities in Visual Generalization

Luoyidi Zhou

School of Medical Information and Artificial Intelligence,

Shandong First Medical University

zhouluoyidi@gmail.com

June 2026

摘要

现代深度神经网络通常具有庞大的参数规模以及非线性层级结构，并在计算机视觉领域取得了优异的性能。然而，其泛化性能来源仍难以被传统统计学习理论解释。在影响视觉模型泛化性能的因素中，数据规模、模型复杂度与输入信息模态是较为基础且可控的变量。因此，本文主要通过实证研究的方式分析上述三个因素对于模型泛化性能的影响。具体而言，在预实验中，本文构建一维非线性函数，通过改变训练样本数量和多项式阶数，观察数据规模与模型复杂度对模型性能的影响。在正式实验中，本文在 CIFAR-10 和 CIFAR-100 上比较不同训练样本规模、不同模型结构以及不同输入信息模态下的模型性能。实验结果表明，训练数据规模增加能稳定提升模型的泛化性能，而模型复杂度的变化并未带来稳定的收益。此外，颜色信息削弱会降低模型性能，而梯度、边缘和小波等显式先验特征对不同模型结构的影响并不一致。本文系统地通过实验分析了上述三个因素对于泛化性能的影响关系，为研究现代深度神经网络提供了实证基础。

Keywords: Deep learning; Generalization; Data scale; Model complexity; Input modalities; Empirical study.

1 前言

近年来，深度神经网络在计算机视觉、自然语言处理、图像视频生成等领域中取得了广泛的应用 [1-3]。随着模型架构的发展与算力的提升，过参数化已经成为现代神经网络的重要特征。然而，传统机器学习观点通常认

为，当模型复杂度超过一定规模时，随着模型复杂度的增加，会导致模型的泛化性能逐渐降低 [4, 5]。然而，已有研究表明，这些过参数化模型在充分拟合训练数据的同时，仍可能保持较好的测试性能 [6-8]，甚至展现出名为“涌现”的能力 [9]。类似的现象引发了人们对于深度学习基础理论的重新思考与研究，寻求能够解释这一现象的方法与理论。

实证研究是一种通过实验观察、对比和归纳现象来形成假设或检验假设的研究方式。为解决深度学习领域长期存在的黑盒问题，实证研究被广泛用于解释和研究模型的表征现象 [10, 11]。其中，在可控数据分布中观察模型行为，是研究复杂模型表征与泛化现象的一种常见方式。即从低维人造数据上做数学与统计学实验，观察其表征现象得到假设，再在大规模实验中进行验证。在众多影响模型泛化性能的因素中，训练数据规模、模型复杂度与输入信息模态是三个较为基础且可控的变量因素。训练数据规模决定了模型可用于建模的经验样本数量，模型复杂度影响着理论上模型可拟合的函数复杂度上限与表征能力，而输入信息模态则决定了输入中可用于建模的信息数量。例如梯度、纹理、边缘等先验特征的引入被认为是为模型提供了一定程度上的约束信息 [?, 12]。

为分析上述因素对模型泛化性能的影响，本文设计了一系列控制变量实验。由于直接在大规模神经网络上分析泛化机制比较困难，其训练过程受到模型结构、优化器、损失函数、学习率调度器、显式正则化策略等众多因素的影响。因此，为得到可控的实验环境，本文通过在预实验中构建一维非线性函数，采用不同阶数多项式进行拟合，并改变训练数据规模，随后观察模型性能。在本

文中，模型性能主要通过训练损失、测试损失和分类任务中的测试准确率进行衡量。尽管预实验得到的结论并不能直接用于论证在深度神经网络中出现的现象，但可以作为后续图像分类实验的现象参考。

基于预实验现象，本文进一步在 CIFAR-10 和 CIFAR-100 图像分类数据集上设计控制变量实验 [13]。具体而言，本文分别从训练数据规模、模型复杂度、输入信息模态三个角度出发，比较 MLP、AlexNet 以及 ResNet 系列模型在不同设置下的模型性能。通过实验，本文试图探究以下问题的答案：第一，训练数据减少是否会使得不同复杂度模型出现明显的泛化性能降低；第二，去除颜色特征是否会导致模型拟合能力与泛化性能的降低，不同模型结构对颜色信息缺失的敏感程度是否存在差异；第三，通过引入边缘、梯度和小波等显式先验特征是否能提高模型的拟合能力与泛化性能。

2 相关工作

2.1 深度神经网络与过参数化

深度神经网络的泛化性能长期以来是机器学习理论研究的重要问题，已有研究从模型参数量、优化过程、数据分布和正则化等角度对该问题进行了分析 [6]。已有研究指出，现代深度网络的参数规模和训练行为使经典复杂度理论难以直接解释其泛化表现 [6, 14]。此外，数据集的规模也深刻影响着模型的性能 [15, 16]。而泛化性能一直是机器学习领域衡量模型实用性的重要概念，尽管过参数化的深度学习模型通常具备不错的泛化性能，但人们对于泛化性能影响因素仍缺乏充分理解。

近十年来，一些研究者开始通过设计可控变量实验研究深度神经网络的表征行为。Zhang 等人的研究表明 [6]，深度神经网络即使在随机标签或随机化输入中也能够拟合训练数据，说明仅依赖包括 VC 维、Rademacher 复杂度以及算法稳定性在内的经典泛化分析工具 [5, 17, 18]，难以充分解释深度网络在实际任务中的泛化表现。该研究推动了人们重新思考深度神经网络泛化性能的来源，尤其是模型容量、优化过程与数据分布之间的关系。

2.2 双重下降、数据规模与模型复杂度

已有研究观察到，深度神经网络的泛化曲线并不总是符合经典的偏差-方差均衡曲线 [4, 7]，双重下降这一现象的出现引发了关于泛化性能的进一步研究。Belkin 等人提出的双重下降曲线将经典的偏差-方差曲线扩展到过参数化区域，指出当模型复杂度超过插值阈值后，泛化

误差可能再次下降 [7]。而 Nakkiran 等人进一步在深度学习任务中观察到模型规模、数据规模与训练时间相关的双重下降现象 [8]，说明模型泛化性能并不总是受到单一变量的影响。因此，本文在图像分类任务中观察训练数据规模、模型复杂度对泛化性能的共同影响。

2.3 视觉模型架构与模型容量

AlexNet 在 ImageNet 数据集的成功表明深度卷积网络能在大规模图像分类任务中学习到有效的类别特征 [1]。残差连接的引入使得上百层的深度卷积网络成功被训练并展现出良好的性能 [19]。相关研究指出，不同网络架构包含不同的归纳偏置，并可能影响模型在相同数据上的泛化性能 [20, 21]。因此，本文同时比较 MLP、AlexNet 和 ResNet 系列模型，以观察不同模型结构对性能的影响。

2.4 输入信息模态与颜色特征

已有研究表明，输入信息中颜色信息的作用具有任务依赖性。在部分视觉任务中，灰度化输入仍使模型保持较好性能 [22]。另一方面，Kanan 和 Cottrell 的研究表明，图像灰度化会影响图像识别的性能 [23]。关于对深度神经网络内部结构的研究表明，卷积神经网络内部存在对颜色敏感的神经元 [24]，这表明颜色信息通常参与模型决策过程，但其重要性会随任务目标和模型结构而变化。因此，通过比较 RGB 彩色图像与灰度图像输入在不同复杂度模型上的表现，有助于分析输入信息丢失与模型性能变化之间的关系。

2.5 先验特征的引入

一些研究通过尝试在原始数据集的基础上引入先验特征，例如图像的边缘、梯度等额外信息或者由小波变换生成的额外特征 [12, 25]，相当于构建了额外的输入信息，为模型提供显式先验。已有研究报告了这类方法在某些设置下可以提高模型的性能，但其收益通常依赖于具体任务、模型结构和训练设置。因此，本文将额外的特征引入视为增加输入信息模态的一种方式，观察其在不同规模模型下对泛化性能的影响。

3 预实验

3.1 实验目标与方法

为获得更可控的实验观察环境，本文首先构建一维非线性函数拟合实验，通过改变多项式阶数，将多项式阶数作为模型复杂度的替代变量，并通过控制训练集样

本数观察模型的性能变化。需要说明的是，该预实验模拟并不能与深度学习中的泛化现象等价，而是作为简单可控环境下进行现象观察，为后续的正式实验提供参考。

在预实验中，本文通过构建如下非线性函数：

$$f(x) = \sin(2\pi x) + 0.5 \cos(5\pi x), \quad x \in [0, 1]. \quad (1)$$

在数据生成阶段，首先在区间 $[0, 1]$ 上均匀采样输入点 x_i ，并通过目标函数 $f(x)$ 生成无噪声标签。随后，为模拟真实观测中的扰动，在标签上加入均值为 0、标准差为 $\sigma = 0.3$ 的高斯噪声：

$$y_i = f(x_i) + \epsilon_i, \quad \epsilon_i \sim \mathcal{N}(0, \sigma^2). \quad (2)$$

训练集与验证集由带噪声样本划分得到，划分比例为 8 : 2。测试集由目标函数在固定区间上均匀采样得到，测试集样本数为 $N_{\text{test}} = 100$ ，且不加噪声，用于评估模型对真实函数的逼近能力。训练集、验证集与测试集的分布如下图 1 所示。




Figure 1: Visualization of the synthetic dataset. Blue dots denote training samples, orange crosses denote validation samples, and the red curve denotes the noiseless target function.

本文分别基于梯度下降优化法训练 $D = 0$ 到 $D = 100$ 的多项式模型。对于给定阶数 D ，多项式模型定义为：

$$\hat{f}_D(x) = \sum_{k=0}^D w_k x^k, \quad (3)$$

其中 $D \in \{0, 1, \dots, 100\}$ 。

同时，本文设置小样本组与大样本组，小样本组的训练样本数量为 $N_{\text{small}} = 50$ ，大样本组的训练样本数量为 $N_{\text{large}} = 150$ 。为观察模型在域外的拟合曲线，本文通过绘图查看了不同复杂度模型在 $[0, 1.1]$ 区间上的拟合曲

线。该域外曲线仅用于辅助域内现象的分析，不作为模型性能的评估参考。

在训练过程中，学习率被设置为 $\eta = 10^{-2}$ ，损失函数为均方误差，梯度下降迭代次数为 30000。均方误差损失函数定义为：

$$\mathcal{L}(w) = \frac{1}{n} \sum_{i=1}^n \left(\hat{f}_D(x_i) - y_i \right)^2. \quad (4)$$

梯度下降更新过程为：

$$w_{t+1} = w_t - \eta \nabla_w \mathcal{L}(w_t). \quad (5)$$

本文首先将输入 x 映射为多项式特征向量：

$$\phi_D(x) = [1, x, x^2, \dots, x^D]. \quad (6)$$

为降低不同阶数特征之间的数值尺度差异，本文对特征矩阵进行标准化处理。设 μ_k 和 s_k 分别为训练集上第 k 阶特征的均值和标准差，则标准化后的特征为：

$$\tilde{\phi}_{D,k}(x) = \frac{\phi_{D,k}(x) - \mu_k}{s_k}. \quad (7)$$

验证集与测试集均使用训练集计算得到的 μ_k 和 s_k 进行处理，以保证不同数据划分中的特征尺度一致，并避免利用验证集或测试集统计量造成信息泄漏。

3.2 实验结果

图 2 展示了在 $N = 50$ 情况下的训练结果。本文观察到了随着多项式阶数增加，模型在训练损失上表现为刚开始较快下降，达到一定模型复杂度后几乎保持不变的现象。然而，验证集与测试集误差呈现出明显的非单调变化，并表现出类似双重下降的趋势。该现象表明，在该实验设置下，模型复杂度与测试误差之间并非简单的单调关系，这一结果与经典偏差-方差权衡中的趋势并不完全一致。另外，图 2 中的最优模型是根据验证集误差最小得出的，事实上在测试集中，二次下降的最低测试集误差小于最优模型的测试集误差。

尽管如此，模型在小样本组上表现出的双重下降所在的区间依然比较狭窄，而相比之下，如图 3 所示， $N = 150$ 组的测试误差曲线没有出现与小样本组相同的高阶多项式误差爆炸现象，而是在复杂度范围内始终维持较低测试误差，且随着多项式阶数的增加表现出一种小幅度下降和上升的循环状态。值得注意的是，在大样本组中，高阶多项式的局部测试误差最小值仍然小于低阶多项式的局部误差最小值。




Figure 2: MSE curves over polynomial degrees under the small-sample setting ($N = 50$). The dashed vertical line indicates the degree selected by the validation MSE.




Figure 3: MSE curves over polynomial degrees under the larger-sample setting ($N = 150$). The dashed vertical line indicates the degree selected by the validation MSE.

图 4 比较了 4 个代表阶数下的测试误差。在 $D = 4$ 、 $D = 22$ 和 $D = 52$ 时，两组训练数据规模的测试误差差异较小，这表明训练样本数量增加并未明显降低这些阶数下的测试误差。而在 $D = 70$ 时， $N = 50$ 组测试误差明显升高， $N = 150$ 组仍保持较低测试误差。

图 5 展示了两组训练数据规模上的不同阶数多项式在训练集、验证集、测试集上的性能表现。由于随机噪声的影响，大样本组训练的模型相比小样本组在训练误差上有所升高，然而随着阶数增加，小样本组在 $D \approx 60$ 后验证集和测试集误差快速上升。

图 6 展示了 $D = 100$ 时两种训练数据规模下的拟合曲线。可以观察到，小样本组在靠近区间右边界及轻微域外区域出现明显震荡，其测试 MSE 达到 20.64；相比之下， $N = 150$ 组的拟合曲线整体更接近目标函数，测试 MSE 为 0.09475。从图 6 可以推测高阶多项式较大的测试误差可能与右侧边界附近训练样本约束不足有关。不




Figure 4: Test MSE of representative polynomial degrees under different training set sizes.

过在域内相邻训练样本之间的区域中，可以观察到大样本组模型的拟合曲线相比小样本组模型震荡幅度要更小。

3.3 分析与讨论

上述结果表明，在该多项式拟合任务中，训练样本数量对高复杂度模型的稳定性具有重要影响。当训练样本较少时，高阶多项式虽然能够较好地拟合训练样本，但其在样本间隙和边界附近的行为缺乏充分约束，因此更容易出现局部震荡和测试误差上升。相比之下，较大的训练样本规模能够在更密集的输入区间上约束模型曲线，使高阶模型在一定范围内保持更稳定的测试表现。

验证集和测试集误差的非单调变化说明，模型复杂度增加并不必然导致测试误差单调上升或下降。该现象与双重下降研究中所关注的非单调泛化曲线具有相似之处，但本文并不将其视为对深度网络双重下降机制的直接证明。更准确地说，该预实验仅说明在一个低维可控的函数拟合任务中，数据规模与模型复杂度之间存在可观察的互相影响作用。

因此，预实验为后续图像分类实验提供了两个启发。第一，在比较不同规模模型时，需要结合训练数据规模进行分析，而不能孤立地讨论模型容量。第二，训练样本数量的变化也可能改变模型可利用的约束条件，从而影响其在不同复杂度下的泛化表现。基于上述观察到的现象与推论，本文在正式实验中设计了数据规模与模型复杂度的交叉对比实验，以分析二者对泛化性能的共同影响。同时，本文还设计了输入信息模态的控制实验，以观察原始信息削弱与显式先验特征引入对模型性能的影响。




Figure 5: Comparison of train, validation, and test MSE curves between $N = 50$ and $N = 150$ across polynomial degrees.




Figure 6: Fitted curves of the $D = 100$ polynomial model under different training set sizes. The curves are plotted on $[0, 1.1]$ to visualize slight out-of-domain behavior.

4 正式实验方法

4.1 数据集

为在真实视觉任务中继续观察预实验中出现的现象，本文采用 CIFAR-10 与 CIFAR-100 数据集进行实验。两个数据集样本均由 32×32 的彩色图像构成，数据集规模都为 50000 张训练图像与 10000 张测试图像。对于 CIFAR-10 分类任务的目标是 10 个类别，而 CIFAR-100 分类任务的目标是 100 个类别，因此，相较于 CIFAR-10，CIFAR-100 类别数量更多且每个类别可用训练样本数量更少，因此可作为更高难度下的图像分类任务。二者可用于观察不同任务难度下的模型性能表现。

4.2 数据规模与复杂度控制实验

为分析训练数据规模与模型复杂度之间的关系，本文构建由训练数据规模和模型结构组成的二维实验矩阵。在训练数据规模方面，本文从 50000 张训练图像中设置 $N \in \{5000, 10000, 20000, 30000, 50000\}$ 五组训练规模。

为减少不同训练子集之间由随机采样带来的额外差异，本文采用固定随机种子对官方训练集样本索引进行一次随机排列，并根据不同训练样本规模截取排列后的前 N 个样本。该方式保证较小训练子集被包含在较大训练子集中。

在模型结构方面，本文选取三类模型作为比较对象：由 3 层隐藏层构成的 MLP、适配图像分类任务的 AlexNet，以及 ResNet 系列模型，各模型的参数量与计算复杂度将在实验结果部分展示。所有模型均针对 CIFAR 系列数据集进行了结构适配，例如减少下采样次数与替换大核卷积为 3×3 卷积。需要指出的是，本文认为模型本身的泛化性能不仅仅与参数量有关，排除外在因素如显式正则化的影响，不同模型中的卷积层设计、残差连接和归一化模块也会引入不同的归纳偏置。因此在本实验中不引入数据增强、权重衰减和 Dropout 等显式正则化策略，以减少外部因素对于模型性能的影响。

4.3 输入信息模态控制实验

为观察模型性能与输入信息模态的关系，本文设计了一系列的输入信息模态控制策略。在削弱输入信息模态的实验中，本文采用式 (8) 将彩色图像映射为灰度图像。为保证模型第一层输入通道数一致，本文将单通道灰度图像复制为三通道灰度图像。在增强输入信息模态的实验中，本文分别引入图像梯度、图像边缘图以及小波分解特征作为附加输入信息。小波分解特征由三个颜色通道分别进行四个子带分解得到。因此，小波增强输入的总通道数为 $3 + 3 \times 4 = 15$ 。通过双线性插值调整至原图像尺寸后，在原始图像的通道维度上进行拼接。基于上述颜色信息削弱与显式特征注入实验，本文观察输入信息变化是否会影响模型性能。

$$Y = 0.299R + 0.587G + 0.114B. \quad (8)$$

4.4 训练设置与评价指标

为客观评估模型的性能，本文采用交叉熵损失作为优化目标，并使用测试集 Top-1 准确率作为主要泛化性能评估指标。其具体参数配置如表 1 所示。

Table 1: 正式实验的训练配置

配置项	设置
优化器	Adam
损失函数	交叉熵损失
初始学习率	10^{-3}
批大小	128
训练轮数	100
输入尺寸	32×32
输入归一化	mean=0.5, std=0.5
随机种子	42

训练过程中记录训练损失、训练准确率、测试损失与测试 Top-1 准确率。其中，训练损失与训练准确率用于衡量模型对训练数据的拟合能力；测试损失与测试准确率用于评估模型在未见样本上的泛化表现。本文将测试准确率作为主要泛化性能指标，并将测试损失作为辅助观察指标，用于分析模型预测置信度变化及过拟合相关现象。




Figure 7: Test Top-1 accuracy curves of ResNet-18 and ResNet-152 under different training set sizes.

5 正式实验结果与分析

5.1 数据规模与复杂度控制实验结果与分析

本节分析训练数据规模与模型复杂度对模型泛化表现的影响。根据第四章的实验设计，本文在不同训练样本规模下分别训练 MLP、AlexNet 和 ResNet 系列模型，并记录各实验设置下的测试 Top-1 准确率与测试损失。表 2 展示了不同训练规模与模型结构下的最佳测试 Top-1 准确率。由于正式实验未单独划分验证集，表中数据采用最高测试准确率及其对应测试损失，该指标主要用于不同实验设置之间的相对比较。

表 2 可以看出，随着训练样本数增加，所有模型的测试准确率均有较大幅度的提升，说明相比增加模型参数规模，增大训练数据规模对泛化性能的收益更加稳定。一种可能的解释是，训练样本规模增加后，数据分布能够对模型的决策函数提供更充分的约束，从而降低模型依赖少量数据进行记忆性拟合的风险。这样的解释与预实验中“样本间隔较大时高阶模型更容易出现严重的局部震荡”现象相似，但由于深度学习模型具有更复杂的内在结构，二者不能直接等价。结合表 2 与训练过程曲线，本文进一步得到以下观察现象。

第一，训练样本数量增加对模型的泛化性能有较大幅度的提升，且不同规模训练集下的测试准确率呈现了较明显的分层现象，如图 7 所示。这表明在本文实验设置下，相比单独增大模型规模，单独扩大训练数据规模对模型泛化性能的提升更加稳定。该结果与已有关于数据规模、模型规模和泛化性能之间复杂关系的研究相一致 [8]。

第二，即使是简单的 3 层隐藏层 MLP，也足以让模型在 50000 张训练集上达到 97.5% 以上的训练准确率，这说明简单的神经网络就具备了非常大的参数空间，使

Table 2: Test loss and Top-1 accuracy at the epoch with the best test accuracy under different training set sizes.

Model	Params (M)	FLOPs (G)	5k		10k		20k		30k		50k	
			Loss	Acc	Loss	Acc	Loss	Acc	Loss	Acc	Loss	Acc
MLP	2.1038	0.0021	3.9727	0.4325	6.5874	0.4750	2.4204	0.5064	1.5105	0.5204	1.4065	0.5470
AlexNet	35.8552	0.2005	4.1721	0.5570	2.7562	0.6228	2.6117	0.6805	2.1627	0.7205	1.0352	0.7654
ResNet-18	11.1740	0.5579	1.5756	0.6396	1.3661	0.7384	1.4130	0.7946	1.1560	0.8243	0.9969	0.8560
ResNet-34	21.2821	1.1635	1.8086	0.6289	1.6392	0.7270	1.1485	0.8059	1.0970	0.8309	0.7648	0.8681
ResNet-50	23.5208	1.3116	1.9280	0.6094	1.7687	0.7107	1.3201	0.7924	1.2631	0.8252	0.8499	0.8709
ResNet-101	42.5130	2.5304	1.9325	0.6190	1.6671	0.7202	1.2853	0.8001	1.1766	0.8267	0.9446	0.8596
ResNet-152	58.1566	3.7508	2.1623	0.5907	1.6284	0.7108	1.2478	0.7906	0.9787	0.8349	0.8902	0.8635

Note: Bold values indicate the best Top-1 accuracy under each training set size, together with the corresponding test loss. For each training size, Loss denotes the test loss at the epoch where the best test Top-1 accuracy is achieved.




Figure 8: Test loss curves of MLP and ResNet-18 under representative training set sizes.

其较好地拟合训练数据。然而其测试损失与准确率显著地低于卷积神经网络，即拟合性能可能与泛化性能不具备明显的相关关系。该现象与 Zhang 等人关于深度网络强拟合能力的研究结论一致 [6]。

第三，从图 8 可以观察到，MLP 出现了在测试准确率趋于稳定后，测试损失持续较大幅度上升的现象。而 AlexNet 也在 $N = 5000$ 的训练中出现了类似的现象。由于本文采用交叉熵损失，该现象可能说明模型在部分错误样本上的错误预测置信度不断增强，导致测试损失升高 [26]。已有研究指出，深度网络通常倾向于先学习数据中的简单模式，随后可能逐渐记忆训练样本中的噪声或非典型模式 [27, 28]。相比之下，ResNet 系列模型的测试损失上升现象相对缓和。但由于 ResNet 引入了残差连接、批归一化与更深的卷积结构，本文无法单独判断该现象的具体原因是否主要由残差连接或者卷积计算的归纳偏置所导致。因此，该问题仍需通过消融实验进一步验证。

第四，模型参数量在达到一定规模后，并未表现出与泛化性能提升之间的稳定正相关关系。由表 2 可见，参数量最大的 ResNet-152 并未在绝大多数指标中取得最

优成绩。在小样本组中，小参数量模型的泛化性能往往小幅度高于大参数量模型。值得一提的是：图 7 中的分层现象即使在 ResNet-18 与 ResNet-152 这两个参数量差距较大的模型之间，也依然存在。该现象也与模型规模、数据规模和训练过程共同影响泛化性能的相关研究相一致 [8]。

接下来，为检验上述观察到的现象是否能够在更高难度任务中保持一致，本文采用相同实验策略在 CIFAR-100 数据集上继续观察数据规模与模型复杂度对泛化性能的影响。CIFAR-100 类别数量更多，且每个类别可用训练样本数量更少，因此相较于 CIFAR-10 具有更高的分类难度。表 3 展示了各模型在不同训练规模下的测试损失与测试 Top-1 准确率。

由表 3 与训练时记录的指标曲线可以观察到以下现象，第一，在 CIFAR-100 上，各模型的测试 Top-1 准确率仍随训练样本规模增加而整体提升。这说明在 CIFAR-100 这一更高难度任务中，增加训练数据规模仍然能够为模型泛化性能带来较稳定收益。与此同时，CIFAR-100 上的整体测试准确率明显低于 CIFAR-10，说明任务难度的增加与单类别可供训练的样本减少会降低模型的泛化性能。

第二，MLP 依旧在全量训练集上达到了最高 95.5% 的训练准确率，这表明即使在类别数更多的 CIFAR-100 上，全连接网络仍能在训练集上取得较高准确率。不过 MLP 在上述两次实验的测试准确率都显著低于卷积神经网络，说明其拟合能力并未转变为有效的泛化性能，表现出明显的过拟合倾向。

第三，测试损失的持续上升不仅仅出现在 MLP 中，AlexNet 在所有训练规模下也出现了测试损失持续以较大幅度上升的现象，而 ResNet 系列模型从 ResNet-50

Table 3: Test loss and Top-1 accuracy on CIFAR-100 at the epoch with the best test accuracy under different training set sizes.

Model	Params (M)	FLOPs (G)	5k		10k		20k		30k		50k	
			Loss	Acc	Loss	Acc	Loss	Acc	Loss	Acc	Loss	Acc
MLP	2.1500	0.0021	9.7786	0.1605	10.5111	0.1905	3.5663	0.2175	3.3469	0.2395	3.2889	0.2645
AlexNet	36.2239	0.2009	13.8161	0.1693	11.0546	0.2047	6.4552	0.2980	4.0105	0.3452	2.2921	0.4324
ResNet-18	11.2201	0.5579	3.5235	0.2810	3.6096	0.3449	2.7450	0.4598	2.3198	0.5437	2.2542	0.6003
ResNet-34	21.3283	1.1635	4.2923	0.2682	4.5034	0.3279	3.1370	0.4383	3.0533	0.5040	3.4087	0.5748
ResNet-50	23.7053	1.3117	8.0754	0.1942	5.3104	0.3130	4.2865	0.4319	3.9654	0.5025	3.1582	0.5862
ResNet-101	42.6974	2.5306	7.6513	0.2055	4.2980	0.2912	4.1712	0.4262	3.9543	0.5025	2.8281	0.5840
ResNet-152	58.3410	3.7510	7.7855	0.1689	4.8352	0.3032	4.2075	0.4231	4.1063	0.5124	3.0009	0.5791

Note: Bold values indicate the best Top-1 accuracy under each training set size, together with the corresponding test loss. For each training size, Loss denotes the test loss at the epoch where the best test Top-1 accuracy is achieved.

开始, 也在 $N = 5000$ 的组中出现类似现象, 但所有 ResNet 模型均在 $N = 10000$ 的情况下保持较好的测试损失控制。本文推测, 残差连接允许模型学习恒等映射, 因此随着参数规模扩大, 模型能够自适应地学习恒等映射来保证深层网络的训练不会带来性能退化问题。然而, 过度拟合与恒等映射学习之间可能存在某种均衡关系。当训练数据规模较少且模型规模较大时, 受单类别可用训练样本数量减少的影响, 模型为了进一步降低训练损失, 可能更容易利用训练样本中的特异性模式或噪声特征, 而不是学习更有利于泛化的表示。

第四, 如图 9 所示, 测试准确率曲线的分层现象尽管相比 CIFAR-10 中较为混乱, 但整体上依然存在。ResNet-18 的测试集最高准确率在所有实验组中均高于 ResNet-152。通过观察实验记录发现, 在最小训练数据规模设置下, ResNet-152 出现了明显的测试损失不断升高现象。本文推测, 在如 CIFAR-100 且 $N = 5000$ 这类图像尺寸较小、训练样本较少的环境中, 模型参数量可能会更明显地影响其泛化性能。这一现象也提示, 在小尺寸图像、训练样本有限且类别数较多的设置下, 模型容量过大可能更容易导致过拟合。相比之下, 在 ImageNet 等更大规模数据集上, 训练数据能够提供更丰富的视觉变化和类别信息 [29], 深层模型可能更容易学习到通用特征表示。因此, 模型复杂度是否带来收益, 很可能取决于数据规模、任务难度与模型结构之间的匹配关系。

5.2 输入信息模态控制实验结果与分析

本节进一步分析输入信息模态变化对于模型性能的影响, 根据第四章的实验方法, 本文以 RGB 图像输入作为基准, 并分别构造灰度输入、梯度增强输入、边缘增强输入和小波特征增强输入 [30, 31], 用于观察颜色信息




Figure 9: Test Top-1 accuracy curves of ResNet-18 and ResNet-152 under different training set sizes on CIFAR-100.

削弱与显式先验特征引入是否会影响模型的拟合能力与泛化性能。模型方面, 基于前述实验结果, ResNet-18 在两个数据集上已表现出较强的泛化性能。因此, 本文选取 MLP、ResNet-18 与 ResNet-50 作为代表模型, 以比较不同模型结构和模型复杂度对输入模态变化的响应。

由表 4 可以看出, 灰度化输入在各模型和数据集上均导致测试准确率下降, 说明颜色信息仍是 CIFAR 图像分类任务中的有效特征, 并能够被 MLP 与卷积神经网络利用。相比之下, 梯度、边缘和小波等显式先验特征对 MLP 的提升较为明显, 但对 ResNet 系列模型未带来稳定提升, 部分实验中甚至导致性能下降。这说明在本实验设置下, 显式先验特征的作用与模型结构密切相关: 对于缺少卷积归纳偏置的全连接网络, 额外先验特征能够提供一定辅助; 而对于卷积网络, 模型本身已能够从原始图像中学习局部纹理、边缘与形状信息, 因此简单的通道拼接并不一定带来稳定收益。

Table 4: Performance comparison under different input information settings on CIFAR-10 and CIFAR-100.

Model	Input mode	Channels	CIFAR-10		CIFAR-100	
			Loss	Acc	Loss	Acc
MLP	RGB	3	1.6158	0.5518	3.2889	0.2645
MLP	Gray	3	2.0550	0.4591	3.9983	0.1789
MLP	RGB+Gradient	4	4.9993	0.5741	3.1528	0.2933
MLP	RGB+Edge	4	1.4887	0.5617	3.2992	0.2835
MLP	RGB+Wavelet	15	1.2822	0.6119	3.1606	0.3107
ResNet-18	RGB	3	0.8830	0.8677	2.2542	0.6003
ResNet-18	Gray	3	1.0849	0.8432	2.6995	0.5527
ResNet-18	RGB+Gradient	4	0.9529	0.8655	2.2802	0.5924
ResNet-18	RGB+Edge	4	0.9646	0.8632	2.2162	0.5956
ResNet-18	RGB+Wavelet	15	0.9621	0.8501	2.3427	0.5786
ResNet-50	RGB	3	0.8185	0.8707	3.1582	0.5862
ResNet-50	Gray	3	1.1017	0.8467	4.0404	0.5286
ResNet-50	RGB+Gradient	4	0.8460	0.8727	3.2978	0.5704
ResNet-50	RGB+Edge	4	0.9701	0.8603	3.3087	0.5677
ResNet-50	RGB+Wavelet	15	0.8399	0.8731	3.4775	0.5612

Note: Bold values indicate the best Top-1 accuracy for each model on each dataset, together with the corresponding test loss. Gray denotes the three-channel grayscale input. RGB+Gradient, RGB+Edge, and RGB+Wavelet denote RGB inputs concatenated with gradient, edge, and wavelet feature maps, respectively. Loss denotes the test loss at the epoch where the best test Top-1 accuracy is achieved.

5.3 实验总结与讨论

本文实验结果表明，训练数据规模、模型复杂度和输入信息模态对泛化性能的影响并非相互独立。训练样本数量增加通常带来更稳定的泛化收益；模型复杂度的收益则依赖于数据规模和任务难度；输入信息模态的变化是否有效，也取决于模型结构能否利用这些信息。对于 MLP 这类缺少图像归纳偏置的模型，额外先验特征能够提供一定辅助；而对于卷积神经网络，简单的通道拼接式先验注入并未带来稳定收益。该结果说明，提升泛化性能不仅依赖于增加训练样本数量、参数量或输入信息量，也依赖于模型结构与数据特征之间的适配关系。

虽然额外输入模态在卷积模型上未取得稳定提升，但这并不意味着显式先验信息没有引入价值。本文认为，其可能原因在于实验采用的是直接通道拼接的先验注入方式，而该方式未必与卷积神经网络的特征提取机制充分适配。对于已具备局部连接、权值共享等图像归纳偏置

的卷积神经网络 [21, 32]，梯度、边缘或小波特征的简单拼接并不一定能够被模型有效利用。因此，提高模型泛化性能的关键不仅在于增加训练数据规模，也在于设计与数据结构和先验信息相适配的模型架构。已有研究表明，在一些任务中，通过注意力机制、跨模态融合或物理先验约束等方式引入先验知识，能够改善模型的学习能力，提高模型性能 [33–35]。与简单的通道拼接相比，这类方法通常将先验信息融入模型结构或损失函数中，以此形成更有效的归纳偏置。

6 结论

本文通过预实验与正式实验，探讨了训练数据规模、模型复杂度与输入信息模态对模型性能，尤其是泛化性能的影响。实验结果表明，训练数据规模的增加能够在 CIFAR-10 与 CIFAR-100 上稳定提升模型的测试准确率，说明训练数据规模仍是影响模型泛化性能的重要因素。相比之下，模型复杂度增加并未稳定带来泛化性能

提升。而输入信息模态实验表明，模型的归纳偏置可能对泛化性能起到关键性作用，即模型能否有效利用输入信息，是影响泛化性能的重要因素。总的来说，提升泛化性能不仅依赖于增加训练样本数量、参数量或输入信息量，也依赖于模型结构与数据特征之间的适配关系。

尽管如此，本文仍存在一些不足。首先，本文实验主要基于 CIFAR-10 与 CIFAR-100 两个小尺寸图像分类数据集，虽然二者能够提供不同任务难度下的对比，但实验结论仍需在更大规模和更复杂的数据集上进一步验证。其次，为突出数据规模、模型复杂度和输入信息模态本身的影响，本文没有引入数据增强、权重衰减、Dropout 和学习率调度等常用训练策略，因此实验结果主要反映受控条件下的现象。此外，本文实验主要基于单一随机种子进行，尚未通过多次重复实验报告均值与方差。最后，本文对显式先验特征的引入主要采用通道拼接方式，尚未进一步研究注意力融合、结构化先验约束或频域神经网络等更复杂的先验注入方法。未来工作可以从更大规模数据集、更丰富的模型架构以及更系统的先验融合方法出发，进一步分析数据规模、模型复杂度与输入信息结构之间的相互作用，从而更深入地理解深度神经网络泛化性能的来源。

参考文献

- [1] Alex Krizhevsky, Ilya Sutskever, and Geoffrey E. Hinton. Imagenet classification with deep convolutional neural networks. In *Advances in Neural Information Processing Systems*, volume 25, 2012.
- [2] Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N. Gomez, Lukasz Kaiser, and Illia Polosukhin. Attention is all you need. In *Advances in Neural Information Processing Systems*, volume 30, 2017.
- [3] Robin Rombach, Andreas Blattmann, Dominik Lorenz, Patrick Esser, and Björn Ommer. High-resolution image synthesis with latent diffusion models. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 10684–10695, 2022.
- [4] Stuart Geman, Elie Bienenstock, and René Doursat. Neural networks and the bias/variance dilemma. *Neural Computation*, 4(1):1–58, 1992.
- [5] Vladimir N. Vapnik and Alexey Ya. Chervonenkis. On the uniform convergence of relative frequencies of events to their probabilities. *Theory of Probability and Its Applications*, 16(2):264–280, 1971.
- [6] Chiyuan Zhang, Samy Bengio, Moritz Hardt, Benjamin Recht, and Oriol Vinyals. Understanding deep learning requires rethinking generalization. In *International Conference on Learning Representations*, 2017.
- [7] Mikhail Belkin, Daniel Hsu, Siyuan Ma, and Soumik Mandal. Reconciling modern machine-learning practice and the classical bias–variance trade-off. *Proceedings of the National Academy of Sciences*, 116(32):15849–15854, 2019.
- [8] Preetum Nakkiran, Gal Kaplun, Yamini Bansal, Tristan Yang, Boaz Barak, and Ilya Sutskever. Deep double descent: Where bigger models and more data hurt. In *International Conference on Learning Representations*, 2020.
- [9] Jason Wei, Yi Tay, Rishi Bommasani, Colin Raffel, Barret Zoph, Sebastian Borgeaud, Dani Yogatama, Maarten Bosma, Denny Zhou, Donald Metzler, et al. Emergent abilities of large language models. *Transactions on Machine Learning Research*, 2022.
- [10] Chris Olah, Alexander Mordvintsev, and Ludwig Schubert. Feature visualization. <https://distill.pub/2017/feature-visualization/>, 2017. Distill.
- [11] Matthew D. Zeiler and Rob Fergus. Visualizing and understanding convolutional networks. In *European Conference on Computer Vision*, pages 818–833. Springer, 2014.
- [12] Vijay Pandey and Shashi Bhushan Jha. Incorporating image gradients as secondary input associated with input image to improve the performance of the cnn model. *arXiv preprint arXiv:2006.04570*, 2020.
- [13] Alex Krizhevsky and Geoffrey Hinton. Learning multiple layers of features from tiny images. Technical report, University of Toronto, 2009.

- [14] Behnam Neyshabur, Srinadh Bhojanapalli, David McAllester, and Nathan Srebro. Exploring generalization in deep learning. In *Advances in Neural Information Processing Systems*, volume 30, 2017.
- [15] Chen Sun, Abhinav Shrivastava, Saurabh Singh, and Abhinav Gupta. Revisiting unreasonable effectiveness of data in deep learning era. In *Proceedings of the IEEE International Conference on Computer Vision*, pages 843–852, 2017.
- [16] Joel Hestness, Sharan Narang, Newsha Ardalani, Gregory Diamos, Heewoo Jun, Hassan Kianinejad, Md. Mostofa Ali Patwary, Yang Yang, and Yanqi Zhou. Deep learning scaling is predictable, empirically. *arXiv preprint arXiv:1712.00409*, 2017.
- [17] Peter L. Bartlett and Shahrar Mendelson. Rademacher and gaussian complexities: Risk bounds and structural results. *Journal of Machine Learning Research*, 3:463–482, 2002.
- [18] Olivier Bousquet and André Elisseeff. Stability and generalization. *Journal of Machine Learning Research*, 2:499–526, 2002.
- [19] Kaiming He, Xiangyu Zhang, Shaoqing Ren, and Jian Sun. Deep residual learning for image recognition. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, pages 770–778, 2016.
- [20] Tom M. Mitchell. The need for biases in learning generalizations. Technical report, Rutgers University, Department of Computer Science, 1980.
- [21] Ian Goodfellow, Yoshua Bengio, and Aaron Courville. *Deep Learning*. MIT Press, 2016.
- [22] Aman Bhatta, Domingo Mery, Haiyu Wu, Joyce Annan, Michael C. King, and Kevin W. Bowyer. Our deep cnn face matchers have developed achromatopsia. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition Workshops*, pages 142–152, 2024.
- [23] Christopher Kanan and Garrison W. Cottrell. Color-to-grayscale: Does the method matter in image recognition? *PLOS ONE*, 7(1):e29740, 2012.
- [24] Martin Engilberge, Edo Collins, and Sabine Süsstrunk. Color representation in deep neural networks. In *Proceedings of the IEEE International Conference on Image Processing*, pages 2786–2790, 2017.
- [25] Qiufu Li, Linlin Shen, Sheng Guo, and Zhihui Lai. Wavelet integrated cnns for noise-robust image classification. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 7245–7254, 2020.
- [26] Chuan Guo, Geoff Pleiss, Yu Sun, and Kilian Q. Weinberger. On calibration of modern neural networks. In *Proceedings of the 34th International Conference on Machine Learning*, volume 70 of *Proceedings of Machine Learning Research*, pages 1321–1330. PMLR, 2017.
- [27] Devansh Arpit, Stanislaw Jastrzebski, Nicolas Balas, David Krueger, Emmanuel Bengio, Maxinder S. Kanwal, Tegan Maharaj, Asja Fischer, Aaron Courville, Yoshua Bengio, and Simon Lacoste-Julien. A closer look at memorization in deep networks. In *Proceedings of the 34th International Conference on Machine Learning*, volume 70 of *Proceedings of Machine Learning Research*, pages 233–242. PMLR, 2017.
- [28] Nasim Rahaman, Aristide Baratin, Devansh Arpit, Felix Draxler, Min Lin, Fred Hamprecht, Yoshua Bengio, and Aaron Courville. On the spectral bias of neural networks. In *Proceedings of the 36th International Conference on Machine Learning*, volume 97 of *Proceedings of Machine Learning Research*, pages 5301–5310. PMLR, 2019.
- [29] Jia Deng, Wei Dong, Richard Socher, Li-Jia Li, Kai Li, and Li Fei-Fei. Imagenet: A large-scale hierarchical image database. In *Proceedings of the IEEE*

Conference on Computer Vision and Pattern Recognition, pages 248–255, 2009.

- [30] John Canny. A computational approach to edge detection. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, PAMI-8(6):679–698, 1986.
- [31] Stéphane G. Mallat. A theory for multiresolution signal decomposition: The wavelet representation. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 11(7):674–693, 1989.
- [32] Robert Geirhos, Patricia Rubisch, Claudio Michaelis, Matthias Bethge, Felix A. Wichmann, and Wieland Brendel. Imagenet-trained cnns are biased towards texture; increasing shape bias improves accuracy and robustness. In *International Conference on Learning Representations*, 2019.
- [33] Jie Hu, Li Shen, and Gang Sun. Squeeze-and-excitation networks. In *Proceedings of the IEEE conference on computer vision and pattern recognition*, pages 7132–7141, 2018.
- [34] Tadas Baltrušaitis, Chaitanya Ahuja, and Louis-Philippe Morency. Multimodal machine learning: A survey and taxonomy. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 41(2):423–443, 2019.
- [35] Maziar Raissi, Paris Perdikaris, and George Em Karniadakis. Physics-informed neural networks: A deep learning framework for solving forward and inverse problems involving nonlinear partial differential equations. *Journal of Computational Physics*, 378:686–707, 2019.